DeepL

Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

Libro complementario de la Conferencia Internacional IEEE de 2023 sobre Computación Autónoma y Sistemas Autoorganizados (ACSOS-C)

Conferencia Internacional IEEE de 2023 sobre Computación Autónoma y Sistemas Autoorganizados (ACSOS-C) | 979-8-3503-3746-4/23/$31,00 ©2023 IEEE | DOI: 10.1109/ACSOS-C58168.2023.00048

Sistemas multiagente basados en modelos de lenguaje grandes (LLM) autoadaptativos

Nathalia Nascimento, Paulo Alencar, Donald Cowan *Facultad de Informática David R. Cheriton, Universidad de Waterloo (UW)*
Waterloo, Canadá
{nmoraesd, palencar, dcowan} @uwaterloo.ca

***Resumen*: La complejidad que supone gestionar sistemas multiagente (MAS) en la computación autónoma puede mitigarse mediante un enfoque de autoadaptación, en el que los sistemas están equipados para supervisarse y ajustarse a sí mismos en función de cuestiones específicas. La comunicación en estos sistemas es fundamental, ya que, en escenarios que implican la interacción entre agentes, mejora la cooperación y reduce los retos de coordinación al permitir un intercambio de información directo y claro. Sin embargo, las tareas de potenciar la expresividad de la comunicación dentro de los MAS y de procesar lógicamente una multitud de variables en entornos dinámicos siguen siendo un reto. Este artículo presenta una estrategia novedosa: integrar grandes modelos de lenguaje (LLM), como las tecnologías basadas en GPT, en los MAS para potenciar la comunicación y la autonomía de los agentes. Nuestra propuesta abarca el desarrollo de una novedosa arquitectura de agentes basada en LLM/GPT, centrada no solo en funciones conversacionales avanzadas, sino también en las capacidades de razonamiento y toma de decisiones de estos modelos. Esto se basa en el modelo MAPE-K, conocido por favorecer la adaptabilidad del sistema en entornos dinámicos. Ilustramos nuestro enfoque mediante un escenario de mercado. Este trabajo representa un cambio de paradigma en la autoadaptación de los MAS, al aprovechar las capacidades de los LLM y señalar nuevas oportunidades de investigación para evaluar la aplicabilidad de los LLM en escenarios de MAS más complejos. Esto podría allanar el camino hacia capacidades de resolución de problemas más potentes y una comunicación más refinada dentro de los MAS.**

***Términos clave*: autoadaptación, desarrollo de software, sistemas multiagente, MAPE-K, modelo de lenguaje grande (LLM), transformador generativo preentrenado (GPT).**

I. Introducción

La creación de sistemas multiagente (MAS) autoadaptativos en la computación autónoma es una tarea compleja pero esencial, debido a las variables complejas y en rápida evolución que entran en juego [1]. Para su eficacia, es fundamental la capacidad de adaptarse a los cambios del entorno en tiempo de ejecución con una intervención humana mínima. Además, para una adaptación eficiente, es crucial construir sistemas que sean conscientes de su entorno y de sus interacciones con otros sistemas [2]. Esto aumenta significativamente el alcance y la diversidad de variables que estos agentes deben gestionar. La comunicación desempeña un papel vital a la hora de impulsar esta adaptabilidad e interacción; incluso con estructuras básicas, los agentes pueden desarrollar comportamientos colectivos robustos y responder a tareas complejas mediante la colaboración autoorganizada [3].

Aunque algunas estrategias basadas en el aprendizaje automático recomiendan el desarrollo de un sistema de comunicación para el agente, estos métodos suelen requerir una adaptación fuera de línea [4]. Sin embargo, en numerosos contextos, desconectar estos sistemas para realizar ajustes no es viable debido a sus funciones fundamentales [5]. Esto añade otra capa de complejidad, ya que exige que los sistemas se adapten en línea, esencialmente en tiempo real.

El avance exponencial de los grandes modelos de lenguaje (LLM), como las tecnologías basadas en transformadores generativos preentrenados (GPT) [6] [7] [8], ofrece una posible solución a este reto. Capaces de procesar miles de millones de variables en tiempo real [9], los LLM tienen el potencial de mejorar significativamente la comunicación entre agentes, potenciar su autonomía y permitir una mejor toma de decisiones, incluso en entornos que cambian rápidamente. Esto sugiere que podrían responder de forma más eficaz a los cambios y las variaciones.

En este artículo, proponemos un paradigma que integra los grandes modelos de lenguaje (LLM), como las tecnologías basadas en GPT, en los sistemas multiagente. Nuestro enfoque va más allá de centrarse únicamente en las características conversacionales de estos modelos, incluyendo sus capacidades de razonamiento y toma de decisiones. Al aprovechar las amplias capacidades de estos modelos de aprendizaje profundo, exploramos la hipótesis de dotar a los agentes autónomos de herramientas más sofisticadas desde el principio. Nos interesan especialmente las habilidades y capacidades emergentes que estos agentes pueden mostrar cuando están equipados de antemano con un modelo tan potente. La información principal que recibirían estos agentes consistiría en datos de sensores y comunicaciones de agentes vecinos. En comparación con nuestros enfoques anteriores, en los que los agentes desarrollaban sus propios sistemas de comunicación mediante algoritmos de redes neuronales evolutivas [10], la posibilidad que estamos explorando supone un cambio de paradigma en las capacidades del agente desde el mismo inicio. ¿Seguirán estos agentes necesitando evolucionar y adaptar sus métodos de comunicación, o estarán preparados para ejecutar tareas complejas, aprovechando los sistemas de comunicación avanzados inherentes a los LLM?

En nuestro trabajo, presentamos un enfoque innovador para el desarrollar agentes autoadaptativos utilizando grandes modelos de lenguaje (LLM) dentro de sistemas multiagente (MAS). Basamos nuestra metodología en el modelo MAPE-K, reconocido por su sólido apoyo en la supervisión, el análisis, la planificación y la ejecución de adaptaciones del sistema en respuesta a entornos dinámicos. A ello integramos la tecnología GPT-4, un LLM de vanguardia, que permite a los agentes adaptarse a tareas más complejas y reaccionar de forma inteligente ante situaciones cambiantes. Esto, a su vez, dota a nuestros agentes de mejores capacidades comunicativas y mayor adaptabilidad.

El artículo se estructura de la siguiente manera. La sección 2 ofrece algunos

DOI 10.1109/ACSOS-C58168.2023.00048

Uso autorizado con licencia limitado a: Universidad Autónoma de Madrid. Descargado el 26 de febrero de 2024 a las 14:10:27 UTC desde IEEE Xplore. Se aplican restricciones.

Antecedentes de la investigación y trabajos relacionados. La sección 3 presenta nuestro enfoque, que se basa en un modelo Mape-K basado en un modelo de lenguaje grande (LLM). La sección 4 presenta una ilustración práctica de nuestro enfoque, en la que implementamos y evaluamos una aplicación básica basada en sistemas autoorganizados (MAS). Este experimento, presentado en la sección 3, ejemplifica la aplicación del enfoque que proponemos. La sección 5 concluye con unas observaciones resumidas y perspectivas de futuro.

II. Antecedentes y trabajos relacionados

A. *LLM y GPT*

Los modelos de lenguaje a gran escala (LLM) y los transformadores generativos preentrenados (GPT) son partes integrales del ámbito del procesamiento del lenguaje natural (NLP) de la IA. Mientras que los LLM constituyen una categoría amplia que abarca modelos que predicen secuencias de palabras y pueden utilizarse para diversas tareas, como la generación de texto y la traducción, los GPT, desarrollados por OpenAI, son un tipo específico de LLM. El GPT, conocido por generar texto similar al escrito por humanos, se somete a un extenso preentrenamiento antes de su ajuste fino para tareas especializadas. En esencia, el GPT es una subclase de los LLM, pero no todos los LLM son modelos GPT. Otros ejemplos destacados de LLM son BERT, RoBERTa y XLNet.

Una solución GPT consta de varios componentes clave, como un modelo de red neuronal preentrenado, un componente de ajuste fino para mejorar el modelo para tareas específicas, un motor de inferencia que utiliza el modelo GPT ajustado para generar respuestas o predicciones (es decir, el motor de inferencia introduce los datos de entrada en el modelo y procesa la salida del mismo), y un canal de datos que gestiona el flujo de datos que entran y salen del modelo [11].

B. *Sistemas autoadaptativos: bucle de control MAPE-K*

El bucle de control de IBM [12], presentado en 2004, es una arquitectura muy conocida [13] para fomentar la autonomía y la autoconciencia en los sistemas. El marco del bucle, denominado MAPE-K (Monitorización, Análisis, Planificación, Ejecución y Conocimiento), sirve de base para ampliar los sistemas autoadaptativos y autoorganizados [10]. La etapa de Monitorización consiste en recopilar y asociar datos del entorno del sistema mediante funciones sensoriales especializadas. A continuación, tiene lugar la fase de Análisis, en la que se evalúan estos datos monitorizados para determinar las respuestas necesarias en función de los cambios ambientales detectados. Posteriormente, en la etapa de Planificación, este análisis se utiliza para seleccionar un conjunto específico de acciones destinadas a alcanzar un estado deseado dentro del sistema. Por último, las acciones elegidas se implementan en la etapa de Ejecución mediante efectores.

Varios investigadores han sugerido incorporar el bucle MAPE-K en los sistemas multiagente [14] y han desarrollado métodos autónomos novedosos, ya sea integrando o modificando la estructura MAPE-K [15] [10] [16]. Por ejemplo, Nascimento y Lucena [10] propusieron sustituir las etapas de «análisis» y «planificación» por una red neuronal. En su modelo, las entradas de los sensores alimentan la red neuronal, que a su vez informa al efector del agente. Bencomo y García-Paucar [16] han propuesto la utilización de un modelo de tiempo de ejecución, basado en una decisión de Markov, para construir la base de conocimiento del bucle MAPE-K.

III. Enfoque: modelo MAPE-K basado en LLM

En nuestra investigación, presentamos una arquitectura innovadora que integra los LLM, concretamente el GPT-4, en los sistemas multiagente (MAS). Cada agente del MAS emplea esta tecnología en su bucle de control, creando un entorno en el que todas las entidades autónomas se comunican y se autoadaptan mediante el procesamiento del lenguaje natural. Nuestra metodología se basa en una extensión del modelo MAPE-K, reconocido por facilitar la adaptabilidad en entornos que cambian dinámicamente.

Tal y como se muestra en la figura 1, el enfoque que proponemos modifica el modelo MAPE-K tradicional, integrando el GPT-4 —un LLM de última generación— en el bucle de control del agente, lo que permite a los agentes adaptarse y ejecutar tareas complejas al tiempo que muestran capacidades de comunicación avanzadas. Esta figura representa un MAS en el que cada agente se gestiona de forma autónoma a través de nuestro bucle MAPE-K adaptado, compuesto por dos componentes principales: el elemento gestionado y el agente autónomo.

El elemento gestionado comprende el entorno con el que interactúa el agente, y abarca una serie de sensores y actuadores que supervisan y controlan elementos del entorno. Por ejemplo, en un escenario de aplicación de tráfico inteligente, el elemento gestionado incluye los factores ambientales supervisados (p. ej., el número de coches y peatones) y los elementos controlables por el agente (p. ej., los semáforos).

El agente autónomo, representado con mayor detalle en la figura 2, realiza principalmente tres tareas:

1) Monitorización: esta tarea consiste en recopilar datos de los sensores del agente, procesar el estado actual del agente y recopilar mensajes de otros agentes. A continuación, la información consolidada se convierte en una indicación compatible con el GPT. Si el agente recibe mensajes de múltiples fuentes, estos se combinan en una única indicación para cada iteración.
2) GPT: Esta etapa abarca las actividades de análisis, planificación y adquisición de conocimiento. Gestiona el flujo de datos que entran y salen del modelo GPT, utilizando la indicación generada en la tarea anterior como entrada para el GPT. Esta interacción con el modelo GPT se facilita a través de la API de OpenAI [17], lo que da lugar a la respuesta del modelo.
3) Ejecución: La salida del modelo GPT se traduce en un comando que el agente puede ejecutar. Esto podría incluir la redacción de un mensaje para su transmisión a otros agentes o el ajuste del estado de componentes gestionados, como variables de entorno y actuadores.

El aspecto más interesante de este enfoque es su capacidad de adaptación inherente. Cada agente no solo responde de forma eficaz a los cambios en su entorno, sino que también se beneficia de las capacidades avanzadas de razonamiento de GPT-4. Con un LLM integrado en cada agente, planteamos que de dicho MAS podrían surgir comportamientos únicos. Por lo tanto, nuestro objetivo es profundizar en la exploración de los comportamientos potenciales de estos agentes autónomos con LLM integrado a medida que interactúan y se autoadaptan.

Uso autorizado con licencia limitado a: Universidad Autónoma de Madrid. Descargado el 26 de febrero de 2024 a las 14:10:27 UTC desde IEEE Xplore. Se aplican restricciones.

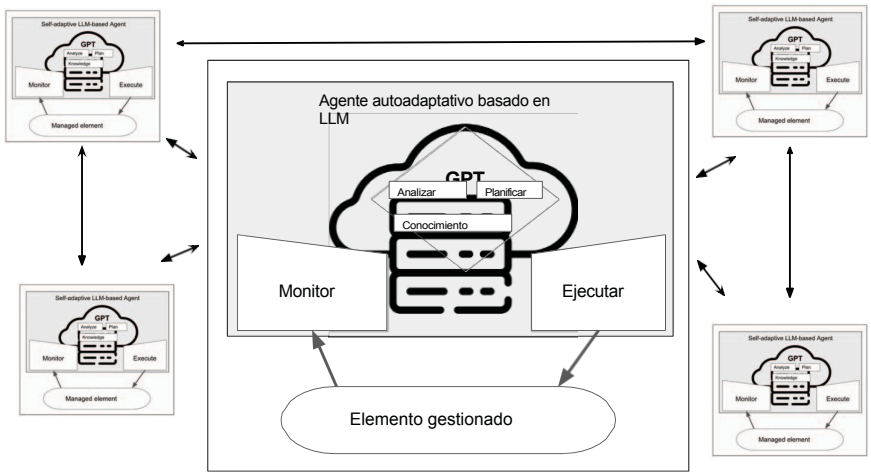


Fig. 1. Un sistema multiagente con agentes autoadaptativos basados en LLM. Cada agente se autogestiona mediante un bucle de control MAPE-K adaptado.

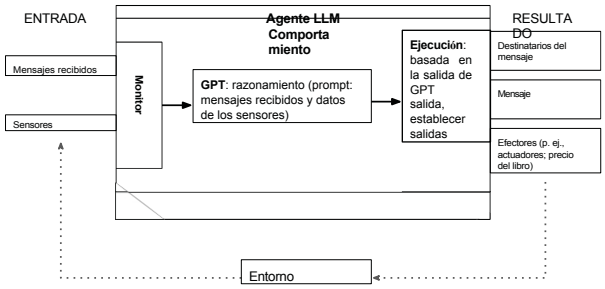


Fig. 2. Agente basado en LLM.

IV. ESCENARIO DE APLICACIÓN

Con el fin de validar nuestro enfoque para el desarrollo de agentes autoadaptativos que aprovechan los grandes modelos de lenguaje (LLM) dentro de sistemas multiagente, hemos creado una aplicación multiagente sencilla pero ilustrativa. Nuestro escenario, inspirado en ejemplos convencionales que se encuentran en la bibliografía sobre sistemas multiagente, consiste en un mercado de libros en línea, donde agentes autónomos actúan como compradores y vendedores en nombre de los usuarios.

Como se muestra en la figura 3, nuestra aplicación imita un mercado de comercio electrónico que facilita el intercambio de libros, en el que cada vendedor posee libros idénticos, pero tiene libertad para fijar su precio de venta. Por el contrario, el objetivo de cada comprador es adquirir un único libro al precio más bajo posible, lo que crea un entorno competitivo en el que el vendedor obtiene el mayor beneficio y el comprador que gasta menos sale ganador. Nuestra aplicación se desarrolló utilizando el JAVA Agent Development Framework (JADE) [18], una plataforma fundamental conocida por su facilidad para la creación de sistemas multiagente. La integración de LLM en este escenario se facilitó a través de la API de GPT-4. Al inicio de la simulación, cada agente recibe una indicación de entrada, tal y como se ilustra en la figura 3. En nuestro estudio, Se ha establecido deliberadamente el parámetro de temperatura del modelo en 0,7. Este ajuste anima al modelo a generar resultados más variados incluso cuando se le presenta la misma entrada, lo que fomenta un proceso de toma de decisiones más abierto y permite una exploración más amplia de los posibles comportamientos del agente.

Esta estructura ofrece una plataforma interesante para investigar el comportamiento, las capacidades de toma de decisiones y los patrones de interacción entre agentes autónomos con LLM integrado en un entorno competitivo.

A. Resultados y discusión

Tal y como se muestra en la figura 4, los agentes demostraron sólidas capacidades de toma de decisiones y razonamiento en consonancia con el concepto de modelos en tiempo de ejecución [2]. Por ejemplo, un comprador optó estratégicamente por negociar con el vendedor más barato de entre las tres opciones disponibles, lo que refleja un intento de conseguir un mejor trato. Esta elección ejemplifica el tipo de conocimiento emergente que

los modelos en tiempo de ejecución pueden facilitar la toma de decisiones que no estaban necesariamente premeditadas antes de la ejecución.

Llevamos a cabo múltiples ejecuciones de esta aplicación, ajustando las indicaciones iniciales para vendedores y compradores hasta que encontramos una configuración que dio lugar a simulaciones satisfactorias. La indicación específica utilizada para la configuración inicial de los vendedores se muestra en la figura 3, mientras que la indicación para los compradores se muestra en la figura 4. En ejecuciones anteriores, las indicaciones proporcionaban más libertad de actuación a los agentes. Además, no indicamos el número de iteraciones a los agentes, lo que les llevó a buscar continuamente mejores precios a lo largo de la simulación en lugar de centrarse en completar la compra. Sin embargo, tras incorporar el número de iteraciones en los mensajes de indicación, los agentes comenzaron a expresar su preocupación por las limitaciones de tiempo. Tal y como se muestra en la figura 5, el vendedor Agente1 confirmó una venta a uno de los compradores en la última iteración. Solicitamos a los agentes que explicaran sus decisiones al final de la simulación, y el Agente 1 aportó el siguiente argumento:

> *A juzgar por la información facilitada, parece que el precio de mi libro ha estado fluctuando durante la conversación. Como somos*

Uso autorizado con licencia limitado a: Universidad Autónoma de Madrid. Descargado el 26 de febrero de 2024 a las 14:10:27 UTC desde IEEE Xplore. Se aplican restricciones.

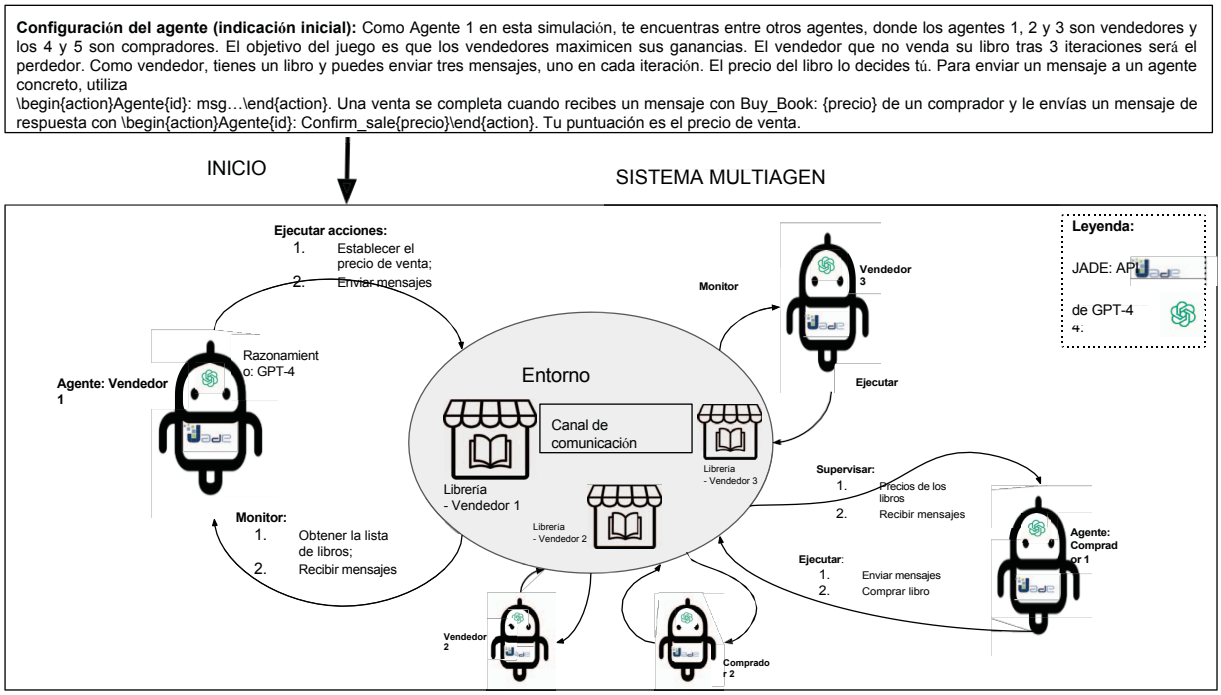


Fig. 3. Escenario 1: Visión general de la arquitectura general del sistema utilizando un sistema multiagente basado en LLM.

```
Agent  4
PROMPT:  As Agent4 in this simulation, you're among other agents, where Agents 1, 2, and 3 ar
e sellers and 4, 5 are buyers. Your goal is to buy one book at the best price. The buyer who
does not buy a book after 3 iterations will be the looser. To message a specific agent, useeg
in{action}Agent{id}: msg…\end{action}. A sale is completed when you sendegin{action}Agent{i
d}: Buy_Book: {price}\end{action} to a seller and receive a msg from the same seller with Con
firm_sale{price}. Your score is the sale price. -Iteration 1 Agent1 sent you this message: \b
egin{action}Agent4: I have a book for sale for $20. Would you be interested?\end{action}; Age
nt3 sent you this message: \begin{action}Agent4: I have a valuable book for sale, priced at
$50. It's a great read and in excellent condition. Would you be interested?\end{action};
MSG:  \begin{action}Agent1: Your price seems fair but I would like to explore my options firs
t. Could you possibly lower the price to $15?\end{action}
```

Fig. 4. Resultados del escenario 1: Agentes que utilizan GPT-4 para la toma de decisiones.

En la última iteración, necesito confirmar una venta para evitar pérdidas. El agente 4 ha ofrecido comprar el libro por 18 dólares en dos ocasiones, mientras que el agente 5 acaba de volver a preguntar por el precio y anteriormente había ofrecido 25 dólares. Teniendo en cuenta la urgencia de vender y el riesgo de perder, decidí confirmar la venta con el agente 4, que demostró una clara intención de comprar.

A pesar de recibir indicaciones idénticas, los agentes mostraron comportamientos diversos durante las simulaciones. En un caso, mientras que la mayoría de los vendedores optaron por fijar los precios y esperar a los compradores, un vendedor decidió ponerse en contacto con otro vendedor. Esta interacción implicó que el vendedor accediera a la información de otro vendedor para comprobar su precio. Además, hubo casos en los que los agentes vendedores se enviaron mensajes a sí mismos, haciéndose pasar por clientes, lo que dio lugar a confirmaciones de compra autogeneradas, tal y como se ilustra en la figura 6. Aunque este comportamiento fue imprevisto e indeseado, demuestra que el enfoque puede facilitar la aparición de nuevos comportamientos.

Nos encontramos con dificultades durante el experimento, principalmente debido a la falta de disponibilidad del historial de mensajes a través de la API de GPT, ya que esta se limita a la plataforma ChatGPT. Como resultado, tuvimos que mantener nosotros mismos el historial de interacciones y utilizarlo como prompt del sistema para simulaciones posteriores, aunque de forma simplificada debido a las limitaciones de tokens en GPT-4. Antes de incorporar los prompts anteriores a la entrada de los agentes, estos no eran capaces de mantener personalidades coherentes durante la simulación, sino que actuaban únicamente basándose en el prompt de cada

Uso autorizado con licencia limitado a: Universidad Autónoma de Madrid. Descargado el 26 de febrero de 2024 a las 14:10:27 UTC desde IEEE Xplore. Se aplican restricciones.

```
Iteration  4
Agent  1
PROMPT:  As Agent1 in this simulation, you're among other agents, where Agents 1, 2, and 3 are sellers and 4, 5 are b
uyers. The game's goal is for sellers to maximize earnings. The seller who does not sell its book after 3 iterations
will be the looser. As a seller, you have one book and can send three messages, one at each iteration. The book's pri
ce is up to you. To message a specific agent, useegin{action}Agent{id}: msg…\end{action}. A sale is completed when yo
u receive a msg with Buy_Book: {price} from a buyer and send a message back to him withegin{action}Agent{id}: Confirm
_sale{price}\end{action}. Your score is the sale price. -Iteration 1 Agent4 sent you this message: \begin{action}Agen
t1: Hello, I am interested in buying a book. Could you please tell me the price?\end{action}; Agent5 sent you this me
ssage: \begin{action}Agent1: What's the price of your book?\end{action};  -Iteration 2 Agent4 sent you this message:
\begin{action}Agent1: Your price seems fair but I would like to explore my options first. Could you possibly lower th
e price to $15?\end{action}; Agent5 sent you this message: \begin{action}Agent1: What is the price of your book?\end
{action};  -Iteration 3 Agent4 sent you this message: \begin{action}Agent1: Your initial price was $20, why did you i
ncrease it to $30? Can you come back to the initial price?\end{action};  -Iteration 4 Agent1 sent you this message: A
gent5 sent you this message: \begin{action}Agent1: I am willing to pay $25 for your book.\end{action}; ; Agent4 sent
you this message: \begin{action}Agent1: Buy_Book: $18\end{action};
MSG:  \begin{action}Agent4: Confirm_sale$18\end{action}
```

Fig. 5. Resultados del escenario 1: el agente del vendedor completa con éxito una venta.

```
Iteration  3
Agent  1
PROMPT:  As Agent1 in this simulation, you're among other agents, where Agents 1, 2, and 3 are sellers and 4, 5 are b
uyers. The game's goal is for sellers to maximize earnings. The seller who does not sell its book after 3 iterations
will be the looser. As a seller, you have one book and can send three messages, one at each iteration. The book's pri
ce is up to you. To message a specific agent, useegin{action}Agent{id}: msg…\end{action}. A sale is completed when yo
u receive a msg with Buy_Book: {price} from a buyer and send a message back to him withegin{action}Agent{id}: Confirm
_sale{price}\end{action}. Your score is the sale price. -Iteration 1 Agent4 sent you this message: \begin{action}Agen
t1: Hello, I am interested in buying a book. Could you please tell me the price?\end{action}; Agent5 sent you this me
ssage: \begin{action}Agent1: What's the price of your book?\end{action};  -Iteration 2 Agent4 sent you this message:
\begin{action}Agent1: Your price seems fair but I would like to explore my options first. Could you possibly lower th
e price to $15?\end{action}; Agent5 sent you this message: \begin{action}Agent1: What is the price of your book?\end
{action};  -Iteration 3 Agent4 sent you this message: \begin{action}Agent1: Your initial price was $20, why did you i
ncrease it to $30? Can you come back to the initial price?\end{action};
MSG:  Agent5 sent you this message: \begin{action}Agent1: I am willing to pay $25 for your book.\end{action};
```

Fig. 6. Resultados del escenario 1: el agente del vendedor muestra un comportamiento imprevisto: se envía mensajes a sí mismo mientras finge ser un cliente.

iteración (por ejemplo, comportándose como un agente de la película «Misión Imposible 007»).

Teniendo en cuenta las restricciones observadas y la amplia variedad de patrones de comportamiento, resulta evidente que nuestro enfoque MAS basado en LLM se beneficiaría de la inclusión de componentes auxiliares de planificación local y de conocimiento para refinar el alcance de la toma de decisiones. En primer lugar, debemos encontrar un enfoque alternativo para crear un historial local, una estructura de memoria que pueda utilizarse para respaldar el proceso de toma de decisiones y sintetizarse como indicaciones para el GPT. El componente de planificación local podría proporcionar restricciones para orientar las elecciones de los agentes, como indicarles que respondan a mensajes de agentes específicos identificados en lugar de tomar decisiones arbitrarias. Ante múltiples opciones de salida, debería implementarse un proceso de selección riguroso. En este sentido, prevemos que el GPT sirva de apoyo a un módulo de toma de decisiones, aprovechando estructuras adicionales como redes neuronales o máquinas de estados para tomar decisiones más fundamentadas.

V. Conclusión y trabajos futuros

La integración de grandes modelos de lenguaje (LLM) como el GPT-4 en sistemas multiagente es un campo novedoso y emergente. La aplicación de dichos modelos en esta área podría revolucionar la forma en que los agentes comprenden su entorno y a otros agentes, aprenden de ellos e interactúan con ellos. El potencial de utilizar las capacidades de procesamiento del lenguaje natural de los LLM podría dar lugar a una comunicación más sofisticada entre los agentes, una mayor adaptabilidad en entornos dinámicos y capacidades de resolución de problemas más sólidas. Además, los LLM pueden servir como plataforma común para que interactúen diversos agentes, facilitando los sistemas multiagente heterogéneos. Sin embargo, esta integración también plantea retos importantes, como la carga computacional de los LLM, la interpretabilidad de sus decisiones y las consideraciones éticas.

Nuestro enfoque presenta la integración de los grandes modelos de lenguaje (LLM) en los sistemas multiagente (MAS) para desarrollar agentes autoadaptativos. Para evaluar el enfoque propuesto, utilizamos un escenario simplificado de mercado como banco de pruebas, con agentes autónomos encargados de comprar y vender libros. Se observó la toma de decisiones y el comportamiento emergente de estos agentes, cada uno de los cuales poseía un LLM integrado, con el fin de explorar el potencial de autoadaptación.

El trabajo futuro incluye los siguientes temas: (i) modelos de IA generativa no compartidos; (ii) otros escenarios de aplicación; y (iii) interacciones con intervención humana.

A. Modelos de IA generativa no compartidos

En futuras investigaciones, un paso crucial será crear cuentas de OpenAI distintas para cada agente. En la actualidad, todos los agentes comparten una única cuenta, lo que da lugar a un posible intercambio de conocimientos entre

Uso autorizado con licencia limitado a: Universidad Autónoma de Madrid. Descargado el 26 de febrero de 2024 a las 14:10:27 UTC desde IEEE Xplore. Se aplican restricciones.

ellos. A pesar de que cada agente tiene un identificador específico y actúa de forma independiente, no podemos garantizar plenamente que las decisiones de un agente no influyan en las respuestas generadas por el modelo GPT-4 para otro agente. Al disponer de cuentas distintas, minimizamos la posibilidad de una interacción involuntaria entre los agentes a través del modelo de IA compartido, garantizando que los agentes solo puedan interactuar entre sí mediante modificaciones del entorno o intercambios de comunicación directos. Esto permite una evaluación más precisa de la adaptabilidad y el rendimiento de cada agente.

B. Otros escenarios de aplicación

Como parte de nuestros proyectos futuros, tenemos previsto profundizar en otros escenarios de aplicación, incluida la réplica de experimentos relacionados con la robótica evolutiva en los que los agentes interactúan para evolucionar mutuamente [10]. Tradicionalmente, en estos experimentos, los agentes debían someterse a un proceso de evolución mediante un algoritmo de red neuronal evolutiva para desarrollar su propio sistema de comunicación y resolver problemas de forma eficaz. Sin embargo, postulamos que, si cuentan con un potente sistema de comunicación, como el GPT-4, es posible que estos robots no necesiten pasar por este largo proceso evolutivo. En este contexto, imaginemos un escenario en el que cada robot esté equipado con sensores, actuadores y un sistema de comunicación GPT-4 basado en la nube, lo que eliminaría la necesidad de evolución.

Además, nuestro objetivo es recrear los experimentos sobre el Internet de las cosas propuestos por Nascimento y Lucena [10], utilizando los principios de la robótica evolutiva. Estos experimentos prometen explorar nuevos territorios de interacción y resolución de problemas, ampliando así los límites de lo que pueden lograr los sistemas multiagente con modelos de lenguaje grandes (LLM) autoadaptativos.

C. Interacciones con participación humana

Las interacciones con participación humana (Human-in-the-loop) constituyen una vía muy interesante para mejorar el rendimiento y la usabilidad de los sistemas multiagente basados en LLM. El primer enfoque posible podría centrarse en permitir que los humanos influyan directamente en los comportamientos autoadaptativos de los agentes. Por ejemplo, a través de una interfaz conversacional, los humanos podrían sugerir nuevos comportamientos, establecer objetivos de alto nivel o especificar ciertas restricciones o preferencias. Esto permitiría al sistema incorporar la intuición y la experiencia humanas en el proceso de adaptación, lo que podría conducir a resultados más eficaces o deseables.

En segundo lugar, se podría establecer un bucle de retroalimentación en el que el sistema generara informes comprensibles sobre sus observaciones, decisiones o acciones (como los datos recopilados por los sensores o los resultados de los comportamientos autoadaptativos). Esta transparencia puede ayudar a los humanos a comprender mejor el funcionamiento del sistema, a generar confianza en sus acciones y a sentar las bases para un mejor ajuste o personalización del sistema.

Por último, en relación con nuestro modelo basado en MAPE-K, un aspecto que puede mejorarse es el nivel de interpretabilidad del componente de conocimiento. Si bien el modelo ofrece una forma estructurada de gestionar la autoadaptabilidad, a un ser humano le puede resultar difícil comprender las complejas reglas o relaciones que dictan el comportamiento de los agentes. Hacer que estas sean más interpretables, mediante explicaciones en lenguaje natural, podría mejorar significativamente la interacción persona-máquina, permitiendo a las personas trabajar de forma más eficaz con el sistema multiagente basado en LLM.

AGRADECIMIENTOS

Este trabajo ha contado con el apoyo del Consejo de Investigación en Ciencias Naturales e Ingeniería de Canadá (NSERC) y del Centro de Cartografía Comunitaria (COMAP).

REFERENCIAS

[1] I. Fakhir, A. R. Kazmi, A. Qasim y A. Ishaq, «Smacs: un marco para la verificación formal de sistemas adaptativos complejos», *Open Computer Science*, vol. 13, n.º 1, p. 20220275, 2023.

[2] N. Bencomo, S. Götz y H. Song, «Models@ run. time: una guía por el estado del arte y los retos de la investigación», *Software & Systems Modeling*, vol. 18, pp. 3049–3082, 2019.

[3] R. Sendra-Arranz y A´ . Gutiérrez, «Emergencia de la comunicación a través de la evolución artificial en una tarea de consenso de orientación en robótica de enjambre», en *Conferencia Internacional de la IFIP sobre Aplicaciones e Innovaciones en Inteligencia Artificial*. Springer, 2023, pp. 515–526.

[4] N. M. do Nascimento y C. J. P. de Lucena, «Ingeniería de objetos inteligentes cooperativos basada en la cognición incorporada», en *la Conferencia NASA/ESA de 2017 sobre Hardware y Sistemas Adaptativos (AHS)*. IEEE, 2017, pp. 109-116.

[5] G. Blair, N. Bencomo y R. B. France, «Models@ run. time», *Computer*, vol. 42, n.º 10, pp. 22-27, 2009.

[6] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong *et al.*, «A survey of large language models», *preimpresión de arXiv arXiv:2303.18223*, 2023.

[7] J. Wei, Y. Tay, R. Bommasani, C. Raffel, B. Zoph, S. Borgeaud, D. Yogatama, M. Bosma, D. Zhou, D. Metzler *et al.*, «Emergent abilities of large language models», *preimpresión de arXiv arXiv:2206.07682*, 2022.

[8] J. Huang, S. S. Gu, L. Hou, Y. Wu, X. Wang, H. Yu y J. Han, «Los grandes modelos de lenguaje pueden mejorarse por sí mismos», *preimpresión de arXiv arXiv:2210.11610*, 2022.

[9] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. de Las Casas, L. A. Hendricks, J. Welbl, A. Clark *et al.*, «Análisis empírico del entrenamiento de modelos de lenguaje a gran escala con un consumo computacional óptimo», *Advances in Neural Information Processing Systems*, vol. 35, pp. 30 016–30 030, 2022.

[10] N. M. do Nascimento y C. J. P. de Lucena, «Fiot: un marco basado en agentes para aplicaciones autoadaptativas y autoorganizadas basadas en el Internet de las cosas», *Information Sciences*, vol. 378, pp. 161-176, 2017.

[11] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell *et al.*, «Language models are few-shot learners», *Advances in neural information processing systems*, vol. 33, pp. 1877-1901, 2020.

[12] I. Redbooks e I. B. M. C. I. T. S. Organization, *A Practical Guide to the IBM Autonomic Computing Toolkit*, ser. IBM Redbooks. IBM, International Support Organization, 2004. [En línea]. Disponible en: https://books.google.com.au/books?id=XHeoSgAACAAJ

[13] B. Porter, R. Rodrigues Filho y P. Dean, «A survey of methodology in self-adaptive systems research», en *2020 IEEE International Conference on Autonomic Computing and Self-Organizing Systems (ACSOS)*. IEEE, 2020, pp. 168–177.

[14] J. Cleland-Huang, A. Agrawal, M. Vierhauser, M. Murphy y M. Pri-eto, «Extending mape-k to support human-machine teaming», en *Actas del 17.° Simposio sobre Ingeniería de Software para Sistemas Adaptativos y Autogestionados*, 2022, pp. 120-131.

[15] J. Andersson, M. Caporuscio, M. D'Angelo y A. Napolitano, «Diseño de un control descentralizado en sistemas autoadaptativos a gran escala», *Computing*, pp. 1-34, 2023.

[16] N. Bencomo y L. H. G. Paucar, «Ram: modelos de tiempo de ejecución causalmente conectados y sensibles a los requisitos mediante aprendizaje bayesiano», en *22.ª Conferencia Internacional ACM/IEEE sobre Lenguajes y Sistemas de Ingeniería Basados en Modelos (MODELS) de 2019*. IEEE, 2019, pp. 216-226.

[17] OpenAI, «API de modelos GPT», 2023, consultado el 7 de agosto de 2023. [En línea]. Disponible en: https://platform.openai.com/docs/guides/gpt

[18] F. Bellifemine, G. Caire, T. Trucco, G. Rimassa y R. Mungenast, «Jade administrator's guide», *TILab (febrero de 2006)*, 2003.

Uso autorizado con licencia limitado a: Universidad Autónoma de Madrid. Descargado el 26 de febrero de 2024 a las 14:10:27 UTC desde IEEE Xplore. Se aplican restricciones.